Mô Hình Luồng Hai Thế Hệ — FLARE-CHRONOS Dual-System Harness

Tài liệu này mô tả *mô hình luồng* đã thiết kế cho bộ điều phối nhận thức kép: hai thế hệ mô hình làm hai việc khác nhau, một chuỗi phân loại có dự phòng, và một cổng kiểm chứng định lượng đứng trước mọi báo cáo. Mọi con số trong tài liệu là **kết quả đo trên chính dữ liệu và yêu cầu của dự án**, không phải đặc tính được công bố của nhà cung cấp.

> Báo cáo tổng thể của dự án: `REPORT.md`. Quyết định kiến trúc: `ADR-0005`, `ADR-0006`, `ADR-0008`, `ADR-0009`. **Phiên bản:** `v1.0.0` — cập nhật 23/10/2026

1. Vì sao hai thế hệ, và mỗi thế hệ làm gì

Hai tầng không phải hai bản sao của cùng một mô hình. Chúng có **hai nhiệm vụ không giao nhau**, và mỗi nhiệm vụ cần một loại mô hình khác nhau.

	Thế hệ 1 — Tầng phản xạ	Thế hệ 2 — Tầng suy luận
Việc	Gán phân tích, định vùng, đánh giá khẩn cấp	Chọn tool, suy luận nhiều bước, viết diễn giải
Mô hình	**Decision model** (`clef-flash` , giao thức typed-questions)	**Chat model** (`beam` , giao thức native chat)
Câu trả lời	Xác suất **hiệu chuẩn** theo từng lựa chọn	Tool call + diễn giải có trích dẫn
Bề mặt tool	**Không** — tầng này không chạm tool	`23` tool tất định + `ask_user_question`
Số lượt gọi mỗi run	`1` (chỉ khi chưa biết phân tích)	`2` (gọi tool, rồi viết)
Token	`976` vào / `0` ra	`3.051` vào / `463` ra mỗi lượt
Nơi chạy	Node suy luận của dự án (GPU cục bộ)	Dịch vụ chat
Chi phí credit	**0** (chạy cục bộ)	Có, theo token

Tầng báo cáo (fast tier) không gọi mô hình lần nào: nó chạy đúng một Atomic Tool và định dạng kết quả thành thẻ dữ kiện. Một yêu cầu tra cứu đơn giản vì vậy **không tốn token, không tốn credit, và không phụ thuộc nhà cung cấp nào còn sống**.

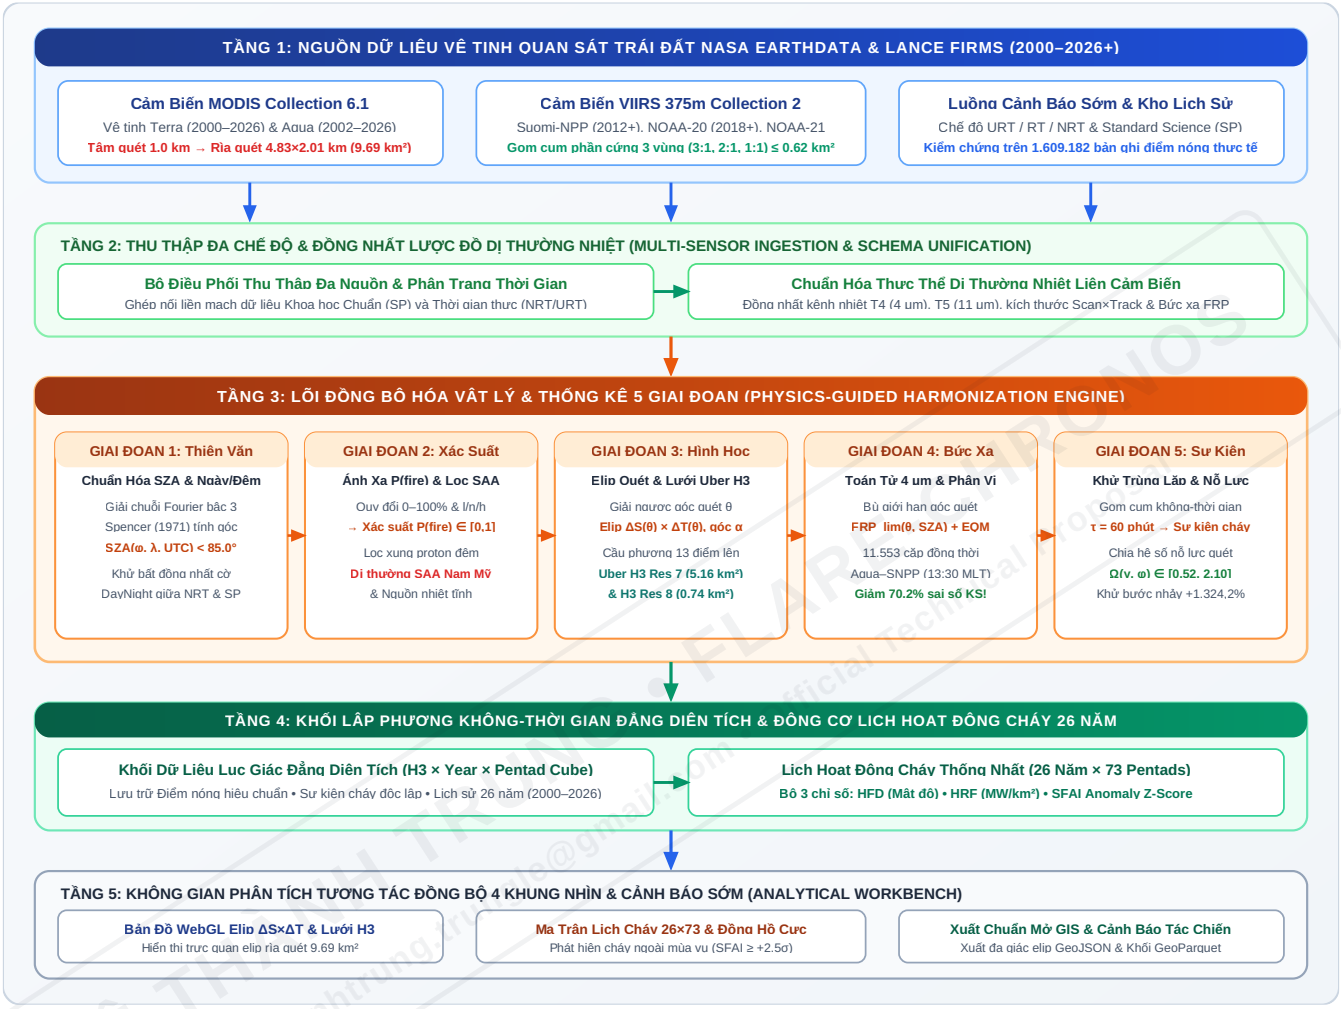
1.1. Vì sao không gộp làm một

Gộp hai tầng làm một mô hình suy luận sẽ hỏng ở đúng chỗ quan trọng nhất: **cảnh báo khẩn cho lính rừng**. Cảnh báo phải trả lời trong mili giây, không được đọc 23 schema tool và không được chờ một mô hình suy luận. Ràng buộc đó là lý do tồn tại của tầng báo cáo, và nó là ràng buộc **kiến trúc** (một lượt gọi mô hình hay không), không phải ràng buộc **tốc độ** (một provider nhanh hay chậm).

LÊ THÀNH TRUNG • FLARE-CHRONOS Official Technical Proposal
lethanhtrung.fungie@gmail.com

2. Luồng

HÌNH KIẾN TRÚC 1: SƠ ĐỒ KIẾN TRÚC TỔNG THỂ 5 TẦNG HỆ THỐNG ĐỒNG BỘ HÓA VẬT LÝ LIÊN CẢM BIẾN FLARE-CHRONOS



2.1. Chuỗi phân loại (tầng phản xạ)

Tầng phản xạ hỏi theo thứ tự, và **ghi lại mỗi lần lùi bậc**:

```
Decision model (typed-questions, xác suất hiệu chuẩn)
        ↓ nếu endpoint không sẵn sàng
Chat model (native chat, tool classify_request)
        ↓ nếu endpoint không sẵn sàng
Trích xuất tất định theo văn bản  ← sàn, không bao giờ thấp hơn
```

Nhánh cuối tồn tại vì trích xuất theo văn bản **sai ở hai chỗ**: nó không nhận ra địa danh nêu gián tiếp, và nó đóng dấu một phân tích cố định. Chuỗi cho phép hệ thống dùng mô hình tốt nhất khi có, và vẫn chạy được khi không có.

2.2. Quy tắc ưu tiên câu trả lời

Trường	Nguồn chính	Dự phòng	Lý do
Vùng	Phân loại (xác suất)	Trích xuất văn bản	Trích xuất đúng `3/8` khi địa danh nêu gián tiếp; phân loại đúng `8/8`

LÊ THÀNH TRUNG • FLARE-CHRONOS • Official Technical Report • lethanhtrung.nguyle@gmail.com

Trường	Nguồn chính	Dự phòng	Lý do
Phân tích	Phân loại	Trích xuất văn bản	Mã do người dùng ghi **luôn thắng** (xem 3.2)
Tầng	**Phân tích đã gán**	Xác suất `is_deliberative`	Xác suất tầng không phân tách được hai lớp (xem 3.3)
Khẩn cấp	Phân loại (xác suất)	Trích xuất văn bản	Ngưỡng nằm giữa khe hở đo được
Khoảng thời gian	Trích xuất văn bản	—	Yêu cầu có thể là **khoảng** (2005→2024); phân loại chỉ cho một năm

2.3. Mã use case do người dùng ghi luôn thắng

Khi yêu cầu chứa mã use case (như `UC-1.1`), mã đó là chỉ định trực tiếp của người vận hành và giữ nguyên. Decision model đồng ý với mã đó ở `18/20` yêu cầu; hai trường hợp lệch (`UC-S1.1` → `UC-S1.3`, `UC-S1.5` → `UC-2.3`) cho thấy phân tích tự động là **ý kiến của mô hình**, không phải chỉ định. Do đó:

- Yêu cầu **có** mã ⇒ dùng mã.
- Yêu cầu **không** có mã ⇒ dùng phân tích mô hình gán (`20/20` đúng trên bộ truy vấn tự nhiên).

---

3. Số đo đo trên dự án

3.1. Bộ truy vấn tự nhiên (20 yêu cầu, không mã use case)

Phép đo	Decision model (`clef-flash`)	Chat model (`gemma4:31b`)
Vùng đúng	**20 / 20**	**20 / 20**
Gán đúng phân tích	**20 / 20**	**20 / 20**
Vùng nêu gián tiếp (8 yêu cầu)	**8 / 8**	**8 / 8**
Tầng đúng (ngưỡng tối ưu)	18 / 20	20 / 20
Khẩn cấp đúng	**20 / 20**	20 / 20
Độ trễ nóng (p50)	**0,66 s**	2,05 s
Token vào mỗi lượt	976	~430

3.2. Đồng thuận với mã use case do người dùng ghi

Mã trong yêu cầu	Phân tích mô hình gán	P(mô hình)	P(mã)
`UC-S1.1`	`UC-S1.3`	0,804	0,021
`UC-S1.5`	`UC-2.3`	0,554	0,167
18 yêu cầu còn lại	trùng mã	—	—

3.3. Hiệu chuẩn và ngưỡng

Xác suất `is_deliberative` của decision model **không tách được hai lớp**:

Nhóm	Khoảng xác suất
Yêu cầu một bước (10)	0,060 – 0,332

LÊ THÀNH TRUNG • FLARE-CHRONOS • Official Technical Proposal • lethanhtrungtrungle@gmail.com

Nhóm	Khoảng xác suất
Yêu cầu suy luận (10)	0,224 – 0,848

⇒ Không có ngưỡng nào đạt `20/20`. Ngưỡng `0,29` là tối ưu theo đo (`18/20`) và **chỉ dùng làm dự phòng** khi phân tích chưa được gán.

Xác suất `urgency` **tách được**:

Nhóm	Khoảng xác suất
Không khẩn cấp (17)	0,004 – 0,099
Khẩn cấp (3)	0,467 – 0,961

⇒ Ngưỡng đặt ở **giữa khe hở** (`0,25`) để biên đệm lớn nhất trước trôi hiệu chuẩn ⇒ `20/20`.

---

4. Chi phí và hiệu quả

Tầng	Lượt gọi mô hình	Token vào	Token ra	Credit	Độ trễ
Báo cáo (không gọi mô hình)	0	0	0	0	~5 ms
Phản xạ (decision, cục bộ)	1	976	0	**0**	0,66 s
Suy luận (chat)	2	3.051/lượt	463/lượt	có	~6 s/lượt

Điểm quan trọng về độ trễ: số giây đo được là thuộc tính của **nhà cung cấp và hạ tầng phục vụ tại thời điểm đo**, không phải thuộc tính của mô hình. Cùng một lượt gọi đo được p50 `1,81 s` và p95 `7,76 s`. Vì vậy độ trễ **không dùng làm tiêu chí chọn mô hình**; tiêu chí là độ đúng trên yêu cầu của dự án, số token, và mức độ tuân thủ gọi tool.

Điểm quan trọng về kiến trúc: chỗ mà thiết kế kiểm soát được là *có gọi mô hình hay không* — số token, số credit, biến động giữa các lần chạy, và việc tầng báo cáo có chạy được khi nhà cung cấp đang sập.

4.1. Sản Phẩm Chạy Được: Xem Một Run Thật

Luồng sự kiện không dừng ở mức đặc tả. Một máy chủ FastAPI (xác thực bằng bearer token, xem ADR-0011) phục vụ đúng hai endpoint mà tài liệu kiến trúc công bố, kèm một trang demo:

```
AI_SERVICE_AUTH=disabled uv run python -m ai_service.serve   # http://127.0.0.1:8765 (chỉ để demo cục bộ)
```

Endpoint	Việc
`GET /api/v1/analysis/stream`	Chạy một Use Case và phát sự kiện của run theo thời gian thực
`POST /api/v1/analysis/resume`	Trả lời một run đang dừng chờ — phê duyệt hoặc từ chối

Trang demo hiện từng sự kiện (phân loại → gọi tool → suy luận → kiểm chứng → phê duyệt → báo cáo), báo cáo cuối cùng, trạng thái kiểm chứng, và **nút phê duyệt** khi run cần người quyết định. Chế độ mặc định là harness tất định nên demo **chạy được ở bất kỳ đâu, không cần khoá API**; `--mode live` dùng mô hình thật.

⇒ Điểm quan trọng: một người đánh giá có thể **xem một run diễn ra** thay vì chỉ đọc mô tả.

LÊ THÀNH TRUNG • FLARE-CHRONOS Official Technical Proposal
lethanhtrung.tlu@gmail.com

5. Bất biến của tầng

1. **Chỉ tool tất định sinh ra số.** Mọi định lượng trong báo cáo đến từ `ToolNode` và được ghi vào `VerifiedFactsLedger`. Mô hình viết diễn giải, harness chèn số.
2. **Cổng kiểm chứng đứng trước khi phát hành.** Bản thảo chứa số không có nguồn, hoặc còn placeholder chưa resolve ⇒ trả về mô hình để viết lại; hết ngân sách sửa ⇒ rơi về bộ sinh tất định.
3. **Tầng báo cáo không suy diễn.** Nó không chạm Domain Diagnostic Tool, không viết diễn giải, không gọi mô hình.
4. **Tầng suy luận không quyết định hành động.** Báo cáo có phê duyệt người thì dừng run, chờ quyết định; bị từ chối ⇒ không phát hành gì.
5. **Không đọc cấu hình agent của máy người dùng.** Mỗi tầng gắn qua *Endpoint Profile* (giao thức, endpoint, model, khoá API, tuỳ chọn request) đọc từ cấu hình tường minh, với thứ tự ưu tiên: biến môi trường → `.env` → YAML.

---

6. Khi một thành phần hỏng

Hỏng ở đâu	Hệ quả	Cơ chế bảo vệ
Decision endpoint không sẵn sàng (node tắt, tunnel SSH rớt, credit hết)	Tầng phản xạ dùng chat model; độ tin cậy chuyển từ `calibrated` sang `self_reported`	Chuỗi phân loại; ghi `triage_fallback` và `triage_confidence_source`; run vẫn hoàn tất
Cả hai classifier không sẵn sàng	Dùng trích xuất tất định	Sàn của chuỗi; ghi lý do; chạy vẫn hoàn tất
Mô hình suy luận dừng im lặng	Mất một lượt	Adapter hỏi lại không kèm suy luận
Endpoint từ chối mức suy luận	Mất suy luận, không mất run	Hỏi lại không kèm suy luận; telemetry báo `thinking_level_supported = false`
Báo cáo chứa số không kiểm chứng được	Bị từ chối	Cổng kiểm chứng + vòng sửa lỗi; rơi về bộ sinh tất định
Người dùng từ chối phê duyệt	Không phát hành báo cáo	Cổng phê duyệt dừng run; quyết định được ghi lại

---

7. Cách chạy lại các số đo

```
# Đường nối tới node suy luận (decision model chạy cục bộ, cổng 11434)
ssh -f -N -L 11434:<decision-node>:11434 <alias>

# Toàn bộ benchmark trên mô hình thật, ghi đo lường từng use case
uv run python apps/ai-service/src/ai_service/run_all_usecases.py --live

# Bộ kiểm thử ngoại tuyến (không gọi mô hình) và bộ kiểm thử trên mô hình thật
uv run pytest -q
uv run pytest -m live -q
```

Kết quả benchmark đầy đủ nằm ở `data/processed/ai_harness_results_live.json`: trạng thái kiểm chứng, số vòng tool, số lần tự sửa, câu hỏi làm rõ, lần lùi bậc phân loại, nguồn độ tin cậy, và token theo từng use case.

LÊ THÀNH TRUNG • FLARE-CHRONOS • Official Technical Report • lethanhtrung.tungle@gmail.com